

تحلیل محاسباتی تصاویر زیستی برای اندازه‌گیری کمی

یک راهنمای گام‌به‌گام بر یک خط لوله کلاسیک قطعه‌بندی و اندازه‌گیری

مستند آموزشی مخزن computational-optical-bioimage-analysis

فهرست مطالب

3	1 این سند چیست و برای چه کسی نوشته شده است
3	1.1 اصل راهنما: ساده بر پیچیده
3	2 داده: چرا این مجموعه دشوار است
3	2.1 ناهمگنی، و دو واقعیتی که کل طراحی را تعیین کردند
4	2.2 گروه‌های مدالیت: یک قاعده، نه یک خوشه‌بندی
4	3 پیش‌پردازش: چهار عمل و دلیل هر کدام
5	3.1 نرمال‌سازی و وارونه‌سازی
5	3.2 حذف پس‌زمینه با white tophat
5	3.3 حذف نویز با فیلتر میانه
5	3.4 CLAHE: همسان‌سازی محلی کنتراست
6	4 استانداردگذاری، و اینکه چرا Otsu نسبت به تبدیل آفین ناوردا است
6	4.1 سه قطعه‌بند
7	5 تبدیل فاصله و watershed: مکانیزم، به زبان شهودی
7	5.1 تبدیل فاصله اقلیدسی
7	5.2 چرا باید تبدیل فاصله را هموار کرد
7	5.3 h_maxima و پارامتر h
7	5.4 دستور کامل
8	6 چرا Dice به‌تنهایی گمراه‌کننده است
8	6.1 خودآزمایی به‌جای مجموعه تست
9	6.2 شمارنده‌های split و merge
9	6.3 تطبیق حریصانه، و چرا اینجا دقیق است
9	6.4 ماتریس IoU به‌صورت برداری
10	6.5 معیارهای گزارش‌شده
10	7 ویژگی‌های هر هسته: regionprops و معنای هندسی
10	8 PCA: چه چیزی را می‌بیند و چرا PC1 اندازه است
11	8.1 نتیجه تضمینی و بی‌اهمیت
11	8.2 تحلیلی که اطلاعات دارد
12	8.3 خوشه‌بندی، و یک بررسی اعتبار

12	9	پایداری اندازه‌گیری: مرحله متمایزکننده
12	9.1	طراحی آزمایش
13	9.2	جدا کردن دو منشأ روند
13	9.3	یک اعتبارسنجی تحلیلی
14	9.4	نتایج: نویز و تاری
14	9.5	محور کنتراست: یک نتیجه پوچ کاملاً تخت
14	9.6	کنتراست ضربدر نویز: نسخه‌ای که اطلاعات دارد
15	9.7	آیا این‌ها فقط شانس یک قرعه‌کشی نیستند؟
15	10	نتایج نهایی، و مقایسه با مراجع منتشرشده
16	10.1	مقایسه با CellProfiler و U-Net: و اینکه چرا این یک برد نیست
17	11	مرور ماژول‌های src/
17	11.1	config.py
17	11.2	io_utils.py
17	11.3	preprocessing.py
17	11.4	segmentation.py
17	11.5	metrics.py
17	11.6	features.py
17	11.7	analysis.py
17	11.8	robustness.py
18	11.9	visualization.py
18	11.10	reports.py و latex_tables.py
18	12	اجرای پروژه
18	13	محدودیت‌ها و کارهای آینده
19		منابع

1 این سند چیست و برای چه کسی نوشته شده است

این متن ترجمه گزارش انگلیسی پروژه نیست. گزارش انگلیسی یک مقاله کوتاه است که می‌گوید چه چیزی اندازه‌گیری شد و نتیجه چه بود. این سند اما یک راهنمای آموزشی است: هدفش آن است که خواننده بفهمد چرا هر تصمیم گرفته شده، هر گام ریاضی چه کاری انجام می‌دهد، و اگر بخواهد کد را تغییر دهد باید کجا را دست بزند.

پروژه یک خط لوله کامل برای اندازه‌گیری کمی از تصاویر میکروسکوپی است: تصویر را می‌خواند، پیش‌پردازش می‌کند، هسته‌های سلولی را قطعه‌بندی می‌کند، از هر هسته ویژگی‌های هندسی استخراج می‌کند، دقت آن اندازه‌گیری را در برابر حقیقت مرجع می‌سنجد، و در پایان نشان می‌دهد وقتی کیفیت تصویر پایین می‌آید این اندازه‌گیری‌ها تا کجا قابل اعتماد می‌مانند.

روش عمده کلاسیک و آماری است، نه یادگیری عمیق. دلیلش این نیست که شبکه عصبی بد است؛ دلیلش این است که هدف پروژه رتبه در جدول مسابقه نیست، بلکه یک خط لوله شفاف است که هر گامش قابل بازرسی باشد و هر عددش به یک پارامتر مشخص در یک فایل مشخص برگردد. یک مدل جعبه‌سیاه می‌تواند عدد بهتری بدهد، اما نمی‌تواند به شما بگوید نویز دقیقاً از کجا وارد شمارش سلول‌ها شد.

1.1 اصل راهنما: ساده بر پیچیده

کسی که این کد را نگه می‌دارد یک پژوهشگر است، نه یک مهندس نرم‌افزار. بنابراین در سراسر پروژه:

- توابع ساده در ماژول‌های ساده. بدون کلاس، بدون دکوراتور، بدون رابط انتزاعی. یک تابع آرایه می‌گیرد و آرایه برمی‌گرداند.
- خروجی CSV است نه parquet: با Excel باز می‌شود و با چشم قابل بازرسی است.
- پردازش ترتیبی است نه موازی. یک اجرای کامل حدود هفده دقیقه طول می‌کشد؛ موازی‌سازی چند دقیقه صرفه‌جویی می‌کند و یک دسته کامل از خطاهای گیج‌کننده اضافه می‌کند.
- یک اسکریپت همه‌چیز را اجرا می‌کند (run_all.py)، نه یک سیستم ساخت.
- توضیحات کد چرا را می‌گویند، نه چه را. خود کد موضوع بحث است؛ آنچه ارزش نوشتن دارد استدلال پشت یک پارامتر یا یک فرمول است.

2 داده: چرا این مجموعه دشوار است

داده پروژه مجموعه BBBC038 است، همان داده مسابقه Data Science Bowl 2018. فقط بایگانی stage1_train استفاده می‌شود، چون تنها بخشی است که حقیقت مرجع در سطح شیء دارد: برای هر هسته یک فایل PNG دودویی جداگانه.

این نکته کوچک، کل پروژه را ممکن می‌کند. اگر حقیقت مرجع فقط یک ماسک دودویی پیش‌زمینه بود، می‌شد گفت «چند درصد پیکسل‌ها درست‌اند» ولی هرگز نمی‌شد گفت «چند هسته درست پیدا شد». همه حرف این پروژه در فاصله میان همین دو جمله است. بنابراین io_utils.build_gt_labels این ماسک‌های تکه‌سته‌ای را در یک تصویر برجسب int32 ادغام می‌کند و همان‌جا بررسی می‌کند که تعداد برجسب‌ها با تعداد فایل‌ها بخواند و هیچ دو هسته‌ای روی هم نیفتند.

در مجموع 670 تصویر و 29,461 هسته حاشیه‌نویسی‌شده، با 9 اندازه تصویر متفاوت و بین 1 تا 375 هسته در یک کادر. هیچ‌جای خط لوله تصویر را تغییر اندازه نمی‌دهد، چون تغییر اندازه مقیاس اشیا را برحسب پیکسل عوض می‌کند و پارامترهایی مثل حداقل مساحت شیء بر حسب پیکسل تعریف شده‌اند.

2.1 ناهمگنی، و دو واقعیتی که کل طراحی را تعیین کردند

هر دو مورد زیر با پیمایش همه 670 تصویر اندازه‌گیری شده‌اند، نه فرض:

جدول 1: ترکیب مجموعه داده پس از گروه‌بندی و تقسیم به بخش توسعه و آزمون.

Modality group	Images	Dev	Test	Nuclei	Inverted
Grayscale fluorescence	546	171	375	23,541	0
Colour histology	103	26	77	4,486	103
Grayscale brightfield	21	3	18	1,434	21
Total	670	200	470	29,461	124

یک: قطبیت مخلوط است. در 124 تصویر از 670 تصویر، هسته‌ها تیره‌تر از پس‌زمینه‌اند (بافت‌شناسی و میدان روشن)، و در بقیه روشن‌تر. یک خط لوله ساده که آستانه Otsu می‌گیرد و کلاس روشن را نگه می‌دارد، روی آن دسته اول با کمال آرامش پس‌زمینه را قطعه‌بندی می‌کند و همچنان عدد Dice قابل قبولی گزارش می‌کند، چون پیش‌زمینه و پس‌زمینه هر دو نواحی بزرگ و همبندند. این خطا سر و صدا نمی‌کند؛ فقط جدول را غلط می‌کند.

به همین دلیل تشخیص قطبیت اختیاری نیست. قاعده ساده است: آستانه Otsu را بگیر، بین چه کسری از پیکسل‌ها در کلاس روشن می‌افتند، و اگر بیش از نصف تصویر بود تصویر را وارونه کن – چون هسته‌ها همیشه اقلیت کادر هستند. این تصمیم یک بار در data/manifest.csv ثبت می‌شود، همراه با کسری که بر اساسش تصمیم گرفته شده و یک ستون بازنویسی دستی، و هرگز دوباره محاسبه نمی‌شود. دو جای مختلف که درباره قطبیت تصمیم بگیرند، دو جایی هستند که می‌توانند با هم اختلاف پیدا کنند.

دو: بیشتر تصاویر عملاً خاکستری‌اند. 108 تصویر رنگ واقعی دارند و بقیه سه کانال یکسان. پس نمی‌شود همه‌جا `convert('L')` زد و امیدوار بود؛ بارگذاری باید صریح باشد: اگر سه کانال یکی بودند یکی را بردار، وگرنه `rgb2gray` بزن.

2.2 گروه‌های مدالیت: یک قاعده، نه یک خوشه‌بندی

تصاویر به گروه‌های تصویربرداری تقسیم می‌شوند تا نتایج به تفکیک گزارش شوند. این تقسیم‌بندی با یک قاعده دو پرسشی انجام می‌شود، نه با KMeans:


1. آیا تصویر رنگی است؟ (میانگین اشباع رنگ بالاتر از یک آستانه)

2. آیا هسته‌ها تیره روی زمینه روشن‌اند؟ (همان پرچم قطبیت)

چرا قاعده و نه خوشه‌بندی؟ چون یک قاعده را می‌شود در یک جمله توضیح داد، در گزارش نوشت، و در manifest.csv با دست تصحیح کرد. یک خوشه‌بندی برازش‌شده هیچ‌کدام از این سه کار را اجازه نمی‌دهد. ضمناً آستانه اشباع در یک بازه خالی از توزیع اندازه‌گیری‌شده نشسته است: هیچ تصویری میانگین اشباعی بین دو مقدار همسایه آن ندارد، پس جابه‌جایی کوچک آستانه هیچ تصویری را جابه‌جا نمی‌کند. پرسش دوم عمداً از پرچم قطبیت گرفته می‌شود و نه از یک آستانه مستقل روی روشنایی. اگر دو آستانه مستقل داشته باشیم، ممکن است تصویری برچسب «فلورسانس» بگیرد و در عین حال وارونه شود – که یک تناقض است، و پیش از این اتفاق افتاده بود.

3 پیش‌پردازش: چهار عمل و دلیل هرکدام

هدف پیش‌پردازش زیباتر کردن تصویر نیست. هدف این است که هیستوگرام شدت تفکیک‌پذیر شود، چون تنها چیزی که یک آستانه سراسری می‌تواند با آن کار کند همان هیستوگرام است. ماژول `src/preprocessing.py` چهار عمل را به ترتیب اعمال می‌کند.



شکل 1: هشت نمونه از هر گروه. این تصویر ابزار اعتبارسنجی قاعده گروه‌بندی است، نه تزئین: اگر قاعده اشتباه باشد، در همین شبکه با چشم دیده می‌شود.

3.1 نرمال‌سازی و وارونه‌سازی

تصویر به بازه $[0, 1]$ برده می‌شود و اگر manifest گفته باشد که هسته‌ها تیره‌اند، وارونه می‌شود. از این نقطه به بعد، هر تابع پایین‌دستی می‌تواند فرض کند هسته‌ها روشن‌اند؛ این فرض یک بار، و در یک جا، برقرار می‌شود.

3.2 حذف پس‌زمینه با white tophat

عملگر white tophat یعنی تصویر منهای بازکرد ریخت‌شناختی آن. شهودش این است: عملگر بازکرد با یک عنصر ساختاری دایره‌ای، هر چیزی را که کوچکتر از آن دایره باشد پاک می‌کند و آنچه بزرگتر است – یعنی میدان روشنایی ناهموار – را نگه می‌دارد. پس تقریب آن از تصویر اصلی، دقیقاً اجسام کوچک را نگه می‌دارد و شیب روشنایی را حذف می‌کند.

نکته حیاتی: شعاع عنصر ساختاری باید به‌راحتی بزرگتر از بزرگترین هسته باشد. اگر کوچکتر باشد، tophat خود هسته‌ها را هم به‌عنوان «چیز کوچک» نمی‌بیند و آن‌ها را می‌خورد. در این مجموعه بزرگترین هسته‌ها حدود شصت پیکسل قطر دارند و شعاع BACKGROUND_TOPHAT_RADIUS با همان منطق انتخاب شده است.

3.3 حذف نویز با فیلتر میانه


فیلتر میانه روی یک دیسک کوچک، نقطه‌های تک‌پیکسلی نویز را حذف می‌کند بدون آنکه لبه‌ها را جابه‌جا کند. فیلتر گاوسی با قدرت معادل، لبه‌ها را جابه‌جا و محو می‌کند – و لبه همان چیزی است که قرار است بعداً آستانه‌گذاری شود.

شعاع بزرگتر شروع می‌کند به پاک کردن «گردن‌های» باریکی که دو هسته چسبیده را به هم وصل می‌کنند، و همان گردن‌ها دقیقاً چیزی هستند که الگوریتم watershed برای جدا کردن هسته‌ها به آن‌ها نیاز دارد. پس این پارامتر یک مصالحه است، نه یک عدد آزاد.

3.4 CLAHE: هم‌سان‌سازی محلی کنتراست

CLAHE هیستوگرام را به‌صورت محلی و در کاشی‌های کوچک صاف می‌کند، پس ناحیه‌ای از تصویر که کم‌نور است تقویت می‌شود بدون اینکه ناحیه پرنور اشباع شود. پارامتری که اهمیت دارد clip_limit است: اگر بزرگ باشد، بافت پس‌زمینه در تصاویر بافت‌شناسی هم تقویت می‌شود و به اشیای کاذب تبدیل می‌شود.

اینجا یک صداقت لازم است: جاروب روی بخش توسعه نشان داد که F1 تا مقدار 0.01 تقریباً ثابت است و بعد از آن به تندی افت می‌کند. مقدار انتخاب‌شده در همان ناحیه تخت است. و مهم‌تر: حذف کامل CLAHE روی این مجموعه تقریباً هیچ هزینه‌ای ندارد. CLAHE جای خود را روی اقلیتی از تصاویر که واقعاً شیب روشنایی دارند ثابت می‌کند، نه روی تصویر متوسط.



شکل 2: خام → نرمال‌شده → نویزگیری‌شده → کنتراست‌تقویت‌شده، یک ردیف برای هر گروه مدالیت.

4 آستانه‌گذاری، و اینکه چرا Otsu نسبت به تبدیل آفین ناوردا است

روش Otsu آستانه‌ای را انتخاب می‌کند که واریانس درون‌کلاسی دو کلاس (تیره و روشن) را کمینه کند – که معادل است با بیشینه کردن واریانس بین‌کلاسی. یعنی آستانه را طوری می‌گذارد که دو توده هیستوگرام تا حد ممکن از هم دور و هرکدام تا حد ممکن فشرده باشند.

حالا نکته‌ای که در فصل پایداری اندازه‌گیری به یک نتیجه کامل تبدیل می‌شود. فرض کنید شدت هر پیکسل را با تبدیل آفین $g(x) = ax + b$ عوض کنیم (یعنی کنتراست را فشرده و جابه‌جا کنیم). واریانس هر کلاس در a^2 ضرب می‌شود. چون همه جمله‌های معیار Otsu در همان a^2 ضرب می‌شوند، آستانه‌ای که معیار را بهینه می‌کرد همان آستانه باقی می‌ماند، فقط با همان تبدیل جابه‌جا شده:

$$t_{0 \dots 0} = a t_{0 \dots 0} + b.$$

و چون آستانه جدید دقیقاً همان‌قدر جابه‌جا شده که خود پیکسل‌ها، مجموعه پیکسل‌هایی که بالای آستانه می‌افتند تغییر نمی‌کند. قطعه‌بندی مو نمی‌خورد.

این یک واقعیت ریاضی است، نه یک حدس، و در فصل 9 دقیقاً همان چیزی است که در نتیجه دیده می‌شود.

4.1 سه قطعه‌بند

- `segment_otsu` – یک آستانه سراسری برای کل تصویر. ارزان، و در سطح پیکسل شگفت‌آور خوب. اما هر دو هسته چسبیده را یک شیء می‌بیند.

- `segment_adaptive` – آستانه محلی. در تئوری در برابر روشنایی ناهموار بهتر است؛ در عمل روی این داده ساختار داخل پس‌زمینه تیره را هم به اندازه هسته‌ها «پیدا می‌کند».
- `segment_watershed` – همان ماسک Otsu، به علاوه یک watershed مبتنی بر تبدیل فاصله که توده‌های به هم چسبیده را می‌شکند. همان پیکسل‌ها، تجزیه متفاوت به اشیا.

5 تبدیل فاصله و watershed: مکانیزم، به زبان شهودی

این بخش قلب فنی پروژه است، پس آهسته پیش می‌رویم.

5.1 تبدیل فاصله اقلیدسی

برای هر پیکسل پیش‌زمینه، تبدیل فاصله مقدار «فاصله تا نزدیک‌ترین پیکسل پس‌زمینه» را می‌نویسد. برای یک دیسک تنها، این تابع یک مخروط است: صفر روی لبه و بیشینه در مرکز، و مقدار بیشینه برابر شعاع دیسک. حالا دو دیسک را که کمی روی هم افتاده‌اند تصور کنید. تبدیل فاصله دو قله دارد (یکی در مرکز هر دیسک) و یک زین در محل اتصال. ارتفاع زین برابر نصف عرض گردنی است که دو دیسک را به هم وصل می‌کند. پس تبدیل فاصله، اطلاعات «کجا دو شیء جدا هستند» را به اطلاعات «کجا دو قله با یک زین از هم جدا می‌شوند» ترجمه می‌کند – و این دومی چیزی است که می‌شود با یک قاعده ساده تشخیص داد.

5.2 چرا باید تبدیل فاصله را هموار کرد

تبدیل فاصله یک لکه دودویی، تکه‌ای-خطی است و پر از فلات‌های دقیقاً مساوی. یعنی به جای یک قله منفرد، یک یال صاف از پیکسل‌های هم‌ارتفاع دارید. عملگر `h_maxima` روی چنین سطحی، برای هر گروه از مقادیر مساوی یک نشانگر تولید می‌کند – یعنی ده‌ها نشانگر برای یک هسته، و در نتیجه یک هسته تکه‌تکه شده. رامحل یک خط است: تبدیل فاصله را با یک گاوسی به انحراف معیار یک پیکسل هموار کنید. این کار تساوی‌ها را می‌شکند و هر لکه یک قله واحد پیدا می‌کند. این یک ترفند زیبایی نیست؛ بدون آن نتیجه آشکارا غلط است.

5.3 `h_maxima` و پارامتر h

عملگر `h_maxima` می‌گوید: یک قله فقط وقتی به عنوان بیشینه مستقل شمرده می‌شود که دست‌کم h واحد بالاتر از زینی باشد که آن را به قله بلندتر همسایه وصل می‌کند. چون در اینجا واحد ارتفاع، پیکسل تبدیل فاصله است، h تفسیر مستقیم دارد:

دو هسته وقتی جدا شمرده می‌شوند که گردن میان آن‌ها دست‌کم h پیکسل در شعاع، باریک‌تر از هسته کوچک‌تر باشد.

اگر h خیلی کوچک باشد، هر هسته کمی ناهموار به دو تکه می‌شکند. اگر خیلی بزرگ باشد، هسته‌های چسبیده ادغام می‌شوند. جاروب روی بخش توسعه در کل بازه مفید کم‌شیب بود، و همین کم‌شیبی خودش یافته است: شعاع هسته‌ها در این مجموعه حدود شش برابر تغییر می‌کند، پس هیچ عمق واحدی برای همه مناسب نیست.

5.4 دستور کامل

```
binary = image > nuclei_threshold(image)
binary = postprocess_mask(binary) # remove small objects and holes
dist = ndi.distance_transform_edt(binary)
```

```

dist      = ndi.gaussian_filter(dist, EDT_SMOOTH_SIGMA)    # break the EDT ties
peaks     = h_maxima(dist, WATERSHED_H_MAXIMA)
markers   = ndi.label(peaks)[0]                            # integer components, not a mask
labels    = watershed(-dist, markers, mask=binary)
labels    = relabel_sequential(labels)[0]

```

چند دام در scikit-image که همگی بی‌صدا نتیجه غلط می‌دهند و در کد رعایت شده‌اند:

- `h_maxima` از `peak_local_max(..., indices=False)` نسخه 0.20 حذف شده است. به‌جای آن استفاده می‌شود که پارامترش هم معنادارتر است.
- نشانگرها باید مؤلفه‌های همبند صحیح از `ndi.label` باشند، نه یک ماسک بولی.
- سطح باید منفی شود: `watershed(-dist, ...)` از کف دره پر می‌کند، و ما می‌خواهیم از قله‌ها شروع کند.
- `watershed_line=True` یک مرز یکپیکسلی را صفر می‌کند. این کار Dice واقعی هزینه دارد و می‌تواند هسته‌های کوچک را زیر آستانه حداقل مساحت ببرد. فقط برای تصاویر نمایشی روشن می‌شود؛ همه معیارها با مقدار `False` محاسبه می‌شوند.
- `clear_border` نباید استفاده شود: حقیقت مرجع این مجموعه هسته‌های ناقص لبه کادر را هم شامل می‌شود.
- (یک همبندی) هشت‌همسایگی (و همان یکی، به‌طور یکسان برای حقیقت مرجع و پیش‌بینی. مخلوط کردن دو همبندی، بی‌صدا تعداد اشیا را عوض می‌کند.

6 چرا Dice به‌تنهایی گمراه‌کننده است

اینجا نقطه اصلی پروژه است.

معیار Dice نسبت همپوشانی پیکسلی را می‌سنجد:

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|},$$

که در آن A مجموعه پیکسل‌های پیش‌زمینه حقیقت مرجع و B همان برای پیش‌بینی است. دقت کنید که در این فرمول هیچ‌جا «شیء» وجود ندارد. Dice فقط می‌داند کدام پیکسل‌ها پیش‌زمینه‌اند؛ نمی‌داند آن پیکسل‌ها به چند جسم تقسیم شده‌اند.

حالا این آزمایش فکری را در نظر بگیرید: قطعه‌بندی‌ای که هر هسته را دقیقاً از وسط به دو نیم می‌کند. هر پیکسل پیش‌زمینه درست است، پس $\text{Dice} = 1.00$. اما هیچ شیء پیش‌بینی‌شده‌ای با هیچ هسته واقعی همپوشانی IoU بالای 0.5 ندارد، پس F1 در سطح شیء برابر صفر است. شما یک قطعه‌بندی کامل و یک شمارش کاملاً غلط دارید، و Dice تفاوتی نمی‌بیند.

این فقط یک مثال نظری نیست: شکستن و ادغام کردن دقیقاً همان کاری است که watershed کلاسیک در آن اشتباه می‌کند. پس گزارش کردن Dice به‌تنهایی، روشی را تحسین می‌کند که نیمی از هسته‌ها را اشتباه شمرده است.

6.1 خودآزمایی به‌جای مجموعه تست

این پروژه عمداً `pytest` ندارد. اما دو خطای محتملش - وارونگی قطبیت و شکستن/ادغام watershed - هر دو بی‌صدا هستند. پس به‌جای یک چارچوب تست، `run_all.py` در ابتدای هر اجرا چهار حالت مصنوعی با پاسخ از پیش معلوم را امتیازدهی می‌کند و نتیجه را چاپ می‌کند.

جدول 2: خودآزمایی با پاسخ معلوم، در آغاز هر اجرا. ردیف دوم همان استدلال بالاست، این بار به صورت یک عدد اندازه گیری شده و نه یک ادعا.

Synthetic case	Dice	F1@0.5	Splits	Merges
identical to ground truth	1.00	1.00	0	0
every nucleus split in two	1.00	0.00	2	0
both nuclei merged into one	0.67	0.00	0	1
no overlap at all	0.00	0.00	0	0

6.2 شمارنده های split و merge

اگر F1 به ما می گوید «چند شیء درست بود»، شمارنده های شکست و ادغام به ما می گویند چرا غلط بود:

- **split**: یک هسته واقعی که با بیش از یک شیء پیش بینی شده هم پوشانی معنادار دارد - یعنی یک هسته به چند تکه شکسته شده است.

- **merge**: یک شیء پیش بینی شده که بیش از یک هسته واقعی را پوشانده است - یعنی چند هسته در هم ادغام شده اند.

اینها درباره توپولوژی هستند نه درباره دقت مرزها، بنابراین آستانه IoU خیلی شلتری می گیرند تا صرفاً اصلاً هم پوشانی دارند یا نه را بسنجند؛ آن آستانه در config.py با نام زیر آمده است.

OVERLAP_IOU_THRESHOLD

6.3 تطبیق حریصانه، و چرا اینجا دقیق است

برای محاسبه F1 باید هر هسته واقعی را به یک شیء پیش بینی شده تخصیص داد. حالت عمومی این مسئله، تخصیص بهینه (Hungarian) است. اما در اینجا همه آستانه ها ≥ 0.5 هستند، و یک شیء نمی تواند همزمان با دو شیء دیگر IoU بالای 0.5 داشته باشد - چون آن دو باید بیش از کل خودشان اشتراک داشته باشند. پس تطبیق یکتا است و روش حریصانه اثباتاً با تخصیص بهینه یکی است. این یعنی یک وابستگی و یک مفهوم کمتر، بدون هیچ از دست دادن درستی.

6.4 ماتریس IoU به صورت برداری

محاسبه IoU میان هر جفت شیء با حلقه های تودرتو، روی حدود بیست و شش هزار شیء، تفاوت میان چند ثانیه و چند ساعت است. راه درست یک جدول توافقی است:

```
pair = gt_labels.ravel() * (n_pred + 1) + pred_labels.ravel()
counts = np.bincount(pair, minlength=(n_gt + 1) * (n_pred + 1))
overlap = counts.reshape(n_gt + 1, n_pred + 1)
union = gt_area[:, None] + pred_area[None, :] - overlap
ious = overlap / union
```

هر جفت برجسته واقعی و برجسته پیش بینی به یک عدد صحیح یکتا کد می شود، np.bincount همه هم پوشانی ها را در یک گذر می شمارد، و اجتماع از مساحت ها به دست می آید.

6.5 معیارهای گزارش شده

- Dice و IoU پیکسلی.
- F1 در سطح شیء در آستانه‌های IoU برابر 0.5 و 0.7، با همان تعریفی که مقاله Data Science Bowl استفاده کرده است.
- امتیاز رسمی DSB: میانگین $TP/(TP + FP + FN)$ روی آستانه‌های IoU از 0.50 تا 0.95 با گام 0.05.
- شمارنده‌های شکست و ادغام.
- خطای شمارش، هم علامت‌دار و هم قدرمطلق. نسخه علامت‌دار با میانه تجمیع می‌شود، چون دم توزیعش سنگین است.
- و هر جدول به تفکیک گروه مدالیت به علاوه یک میانگین ماکرو گزارش می‌شود. گروه‌ها به شدت نامتوازن‌اند؛ یک میانگین ساده روی کل مجموعه، شکست کامل روی کوچکترین گروه را پنهان می‌کند.

7 ویژگی‌های هر هسته: regionprops و معنای هندسی

- پس از قطعه‌بندی، src/features.py با regionprops_table از هر هسته یک ردیف عدد می‌سازد. معنای هندسی هر کدام:
- area و equivalent_diameter_area: اندازه. دومی قطر دایره‌ای است که همان مساحت را دارد.
 - perimeter و feret_diameter_max: طول مرز، و بلندترین فاصله میان دو نقطه شیء.
 - axis_major_length و axis_minor_length: محورهای بیضی‌ای که همان ممان‌های مرتبه دوم را دارد.
 - eccentricity: صفر برای دایره، به سمت یک برای یک پاره‌خط.
 - solidity: مساحت تقسیم بر مساحت پوش محدب. مقدار یک یعنی هیچ فرورفتگی ندارد.
 - extent: مساحت تقسیم بر مساحت کادر محیطی. می‌گوید شیء چقدر از کادرش را پر کرده است.
 - euler_number: تعداد مؤلفه‌ها منهای تعداد حفره‌ها. برای یک لکه توپر برابر یک است.
- دو ستون مشتق هم اضافه می‌شوند که هر دو مستقل از مقیاس‌اند:

$$\frac{\text{perimeter}^2}{\text{area}} = \frac{4\pi A}{P^2}, \quad \frac{\text{axis_major_length}^2}{\text{axis_minor_length}^2} = \frac{\text{axis_major_length}^2}{\text{axis_minor_length}^2}.$$

دایرگی برای دایره کامل یک است و هرچه مرز ناهموارتر شود کمتر می‌شود. استقلال از مقیاس اینجا مهم است: می‌خواهیم بتوانیم شکل یک هسته کوچک فلورسانس را با شکل یک هسته بزرگ بافت‌شناسی مقایسه کنیم، بدون آنکه اندازه پاسخ را تعیین کند.

ویژگی orientation عمداً حذف شده است: برای جسمی که تقریباً گرد است، زاویه یک عدد دلخواه است.

8 PCA: چه چیزی را می‌بیند و چرا PC1 اندازه است

تحلیل مؤلفه‌های اصلی به زبان ساده: داده‌ها را در فضایی که هر ویژگی یک بعد است در نظر بگیرید. PCA جهتی را پیدا می‌کند که ابر نقاط در آن بیشترین پراکندگی را دارد (PC1)، بعد جهتی عمود بر آن با بیشترین پراکندگی باقی‌مانده (PC2)، و همین‌طور. هر مؤلفه یک ترکیب خطی از ویژگی‌های اصلی است، و ضرایب آن ترکیب را بارگذاری می‌نامیم.

جدول 3: توزیع هر ویژگی روی 26,112 هسته اندازه‌گیری‌شده.

Feature	Mean	SD	Min	Median	Max
area	538.540	672.439	30.000	335.000	42378.000
perimeter	82.305	49.581	17.071	72.184	1056.278
eccentricity	0.709	0.163	0.000	0.733	1.000
solidity	0.940	0.057	0.095	0.960	1.000
extent	0.726	0.094	0.049	0.744	0.975
axis_major_length	29.781	19.577	6.284	26.180	1277.272
axis_minor_length	19.003	10.478	1.605	17.439	206.575
equivalent_diameter_area	23.079	12.372	6.180	20.653	232.287
euler_number	1.000	0.024	-1.000	1.000	1.000
feret_diameter_max	30.640	18.985	6.708	27.203	1024.031
intensity_mean	0.261	0.151	0.010	0.218	0.826
intensity_std	0.057	0.049	0.002	0.042	0.359
circularity	0.836	0.166	0.013	0.867	1.294
aspect	1.696	2.790	1.000	1.470	297.600

8.1 نتیجه تضمینی و بی‌اهمیت

اگر PCA را روی همه ویژگی‌های ریخت‌شناختی اجرا کنیم، PC1 حدود 0.555 از واریانس را توضیح می‌دهد و روی area، perimeter، هر دو محور، قطر معادل و قطر Feret با یک علامت بار می‌شود. این نتیجه از پیش معلوم بود. شش ستون از یازده ستون، در واقع یک چیز را اندازه می‌گیرند: بزرگی. PCA هم دقیقاً همین را پیدا می‌کند و آن را «PC1» می‌نامد. این خاصیت مجموعه ویژگی‌هاست، نه کشفی درباره هسته‌ها. گزارش صادقانه‌اش این است که بگوییم بله، PC1 اندازه است، و بعد سراغ تحلیلی برویم که اطلاعات دارد.

جدول 4: بارگذاری‌های PCA روی ویژگی‌های شکلی مستقل از مقیاس.

Feature	PC1	PC2	PC3
circularity	0.501	0.099	-0.571
solidity	0.427	0.532	-0.189
eccentricity	-0.407	0.573	-0.352
extent	0.456	0.376	0.688
aspect	-0.440	0.488	0.205

8.2 تحلیلی که اطلاعات دارد

همان PCA را فقط روی ویژگی‌های شکلی مستقل از مقیاس اجرا می‌کنیم: دایرگی، solidity، خروج از مرکز، extent و نسبت محورها. حالا PC1 حدود 0.659 از واریانس را توضیح می‌دهد و معنایش روشن است: یک محور گردی. دایرگی، solidity و extent یک طرف، و خروج از مرکز و نسبت محورها طرف دیگر. یعنی یک هسته یا گرد و فشرده است، یا کشیده و ناهموار. یک نکته فنی: ستون‌های اندازه‌مانند پیش از استانداردسازی با log1p تبدیل می‌شوند. بدون آن، دم راست سنگین هسته‌های بزرگ بافت‌شناسی بر PC1 مسلط می‌شود و بارگذاری‌ها دیگر قابل تفسیر نیستند. همچنین ویژگی‌ای که روی تقریباً همه اشیاء یک مقدار ثابت دارد – مثل euler_number که برای 99.95 درصد هسته‌ها برابر یک است – پیش از PCA حذف می‌شود؛ استانداردسازی چنین ستونی، آن دوازده شیء باقی‌مانده را به هشتاد انحراف معیار دورتر پرتاب می‌کند و آنجا یک مؤلفه و سپس یک خوشه کامل برای خودشان می‌سازند.

8.3 خوشه‌بندی، و یک بررسی اعتبار

روی مؤلفه‌های اصلی شکل، KMeans اجرا می‌شود و k با معیار سیلوئت انتخاب می‌شود. سیلوئت برای هر نقطه می‌سنجد که چقدر به خوشه خودش نزدیکتر است تا به نزدیکترین خوشه دیگر؛ میانگین آن روی همه نقاط، کیفیت خوشه‌بندی را می‌دهد. نتیجه، k برابر 2 با سیلوئت 0.479 است: هسته‌های گرد و فشرده در برابر هسته‌های کشیده و نامنظم.

اما اینجا یک تله هست. اگر یک خوشه تقریباً تماماً از یک گروه مدالیتة آمده باشد، آن خوشه نوع تصویربرداری را بازیابی کرده، نه زیست‌شناسی را. این یک بررسی اعتبار است، نه یک یافته. برای همین همان خوشه‌بندی درون بزرگترین گروه مدالیتة هم تکرار می‌شود، جایی که نوع تصویربرداری ثابت نگه داشته شده است – و همان ساختار دوخوشه‌ای باقی می‌ماند.

جدول 5: دو خوشه شکلی: هندسه میانه هر کدام، و سهم هر گروه مدالیتة در آنها.

Cluster	Nuclei	Circularity	Solidity	Eccentricity	Extent	Aspect	Colour histology	Grayscale brightfield	Grayscale fluorescence
0	6,786	0.648	0.900	0.880	0.632	2.103	0.275	0.145	0.580
1	19,326	0.905	0.965	0.685	0.763	1.373	0.101	0.038	0.861

9 پایداری اندازه‌گیری: مرحله متمایزکننده

تا اینجا گفتیم خط لوله چقدر خوب کار می‌کند. این مرحله می‌گوید آن عدد تا کجا قابل اعتماد است.

9.1 طراحی آزمایش

یک نمونه طبقه‌بندی شده از تصاویر (از هر گروه مدالیتة به تعداد برابر) برداشته می‌شود، و در طول چهار محور خراب می‌شود. برای هر تصویر خراب‌شده، **کل خط لوله دوباره اجرا می‌شود** – پیش‌پردازش، قطعه‌بندی، اندازه‌گیری، امتیازدهی.

Axis	Parameterization	Levels
Gaussian noise	$\text{img} + N(0, \text{sigma})$	0, .01, .02, .05, .10, .20
Poisson / shot	$\text{poisson}(\text{img} * \text{peak}) / \text{peak}$	inf, 1000, 300, 100, 30, 10
Blur	$\text{gaussian}(\text{img}, \text{sigma}) \text{ px}$	0, .5, 1, 2, 4, 8
Contrast	$(\text{img} - \text{median}) * c + \text{median}$	1, .7, .5, .3, .15, .05

سه تصمیم طراحی که همگی اهمیت دارند:

خرابی روی تصویر خام اعمال می‌شود، پیش از پیش‌پردازش. اگر بعد از نرمال‌سازی خرابی را اضافه کنیم، چیز فیزیکی‌ای اندازه نگرفته‌ایم: خط لوله اصلاً برای همین وجود دارد که با تصویر بد کنار بیاید، پس باید اجازه داشته باشد واکنش نشان دهد.

سطح صفر هر محور، عمل همانی است. یعنی هر چهار منحنی از یک نقطه مشترک شروع می‌شوند و افت را می‌شود به عنوان افت خواند، نه به عنوان اختلاف مقیاس میان چهار آزمایش متفاوت.

دانه تصادفی هر خانه جداگانه ساخته می‌شود از ترکیب (seed, image, axis, level). پس خانه‌ها مستقلاند و اضافه کردن یک سطح جدید، بقیه نتایج را دوباره تاس نمی‌ریزد.

9.2 جدا کردن دو منشأ روند

اینجا یک مسئله روش شناختی ظریف هست. خراب کردن تصویر هم قطعه بندی را عوض می کند و هم خود مقادیر شدت را. پس اگر فقط روند سرتاسری را اندازه بگیریم، نمی توانیم بگوییم کدام یک عامل بود. رامحل ساده است: هر تصویر خراب شده دو بار اندازه گیری می شود.

1. تصویر خراب $\square$ ماسک پیش بینی شده - آنچه واقعاً اتفاق می افتد.
 2. تصویر خراب $\square$ ماسک حقیقت مرجع - حساسیت خالص اندازه گیری ویژگی، با قطعه بندی ثابت نگه داشته شده.
- تفاضل این دو، سهم قطعه بندی است. بازوی سومی (تصویر تمیز با ماسک حاصل از تصویر خراب) نمایشی تکراری از همان کمیت می دهد و برای سادگی کنار گذاشته شده است.

9.3 یک اعتبارسنجی تحلیلی

تحت نویز جمع شونده $N(0, \sigma)$ ، می توان پیش بینی کرد که چه باید بشود:

- intensity_mean هر شیء نااریب می ماند، چون امید ریاضی نویز صفر است.
 - intensity_std هر شیء باید مطابق $\sqrt{s^2 + \sigma^2}$ متورم شود، چون واریانس ها جمع می شوند.
- اندازه گیری با این پیش بینی مقایسه می شود. تا سطوح بالای نویز تطابق نزدیک است و در شدیدترین سطح، بریدگی در کران های شدت باعث انحراف می شود. این کار «ویژگی ها جابه جا می شوند» را از یک ادعا به یک هارنس اعتبارسنجی شده تبدیل می کند، و نتیجه عملی اش یک محدودیت تفسیری است: **ویژگی های شدت میان سطوح نویز قابل مقایسه نیستند**، پس هر نتیجه گیری درباره پایداری باید بر ریخت شناسی و قطعه بندی تکیه کند.

جدول 6: intensity_std اندازه گیری شده در برابر پیش بینی $\sqrt{s^2 + \sigma^2}$.

σ	Group	Measured SD	Predicted SD	Relative error	Measured mean
0	Colour histology	0.0749	0.0749	0.0000	0.3850
0	Grayscale brightfield	0.0703	0.0703	0.0000	0.3821
0	Grayscale fluorescence	0.0435	0.0435	0.0000	0.2017
0.01	Colour histology	0.0756	0.0756	-0.0005	0.3850
0.01	Grayscale brightfield	0.0709	0.0710	-0.0016	0.3825
0.01	Grayscale fluorescence	0.0447	0.0447	-0.0001	0.2020
0.02	Colour histology	0.0773	0.0776	-0.0037	0.3856
0.02	Grayscale brightfield	0.0731	0.0731	-0.0001	0.3822
0.02	Grayscale fluorescence	0.0476	0.0479	-0.0066	0.2017
0.05	Colour histology	0.0901	0.0901	-0.0002	0.3857
0.05	Grayscale brightfield	0.0871	0.0863	0.0096	0.3805
0.05	Grayscale fluorescence	0.0671	0.0663	0.0115	0.2032
0.1	Colour histology	0.1258	0.1250	0.0063	0.3826
0.1	Grayscale brightfield	0.1218	0.1222	-0.0037	0.3808
0.1	Grayscale fluorescence	0.1065	0.1091	-0.0241	0.2016
0.2	Colour histology	0.2068	0.2136	-0.0315	0.3894
0.2	Grayscale brightfield	0.2047	0.2120	-0.0342	0.3875
0.2	Grayscale fluorescence	0.1773	0.2047	-0.1340	0.2216

جدول 7: میانۀ $F1@0.5$ در برابر انحراف معیار نویز گاوسی، به تفکیک گروه.

Group	0	0.01	0.02	0.05	0.1	0.2
Colour histology	0.760	0.775	0.760	0.763	0.718	0.674
Grayscale brightfield	0.452	0.441	0.438	0.397	0.151	0.082
Grayscale fluorescence	0.922	0.921	0.927	0.902	0.718	0.467

9.4 نتایج: نویز و تاری

فلورسانس خاکستری تا حدود σ برابر 0.05 مقاومت می‌کند و بعد فرو می‌ریزد (از 0.922 به 0.467). میدان روشن خیلی زودتر و شدیدتر شکست می‌خورد (0.452 به 0.082): هسته‌هایش از ابتدا هم به‌سختی از پس‌زمینه بالاتر بودند. بافت‌شناسی رنگی مقاوم‌ترین است (0.760 به 0.674)، چون هسته رنگ‌آمیزی‌شده فاصله شدت بزرگی با بافت اطرافش دارد.

جدول 8: میانۀ $F1@0.5$ در برابر انحراف معیار تاری گاوسی، بر حسب پیکسل.

Group	0	0.5	1	2	4	8
Colour histology	0.760	0.755	0.755	0.739	0.614	0.326
Grayscale brightfield	0.452	0.446	0.451	0.430	0.400	0.246
Grayscale fluorescence	0.922	0.923	0.921	0.882	0.664	0.349

درباره تاری یک هشدار روش‌شناختی لازم است: یک σ ثابت بر حسب پیکسل، برای گروه‌های مختلف توهین یکسانی نیست. شعاع هسته‌ها در این مجموعه تقریباً از پنج تا سی پیکسل تغییر می‌کند، پس برای $\sigma = 4$ برای یک هسته بزرگ بافت‌شناسی ملایم و برای یک هسته کوچک فلورسانس نابودکننده است. به همین دلیل نتیجه در مخزن، علاوه بر این، بر حسب σ تقسیم بر شعاع میانۀ هسته همان تصویر هم رسم شده است.

9.5 محور کنتراست: یک نتیجه پوچ کاملاً تخت

محور کنتراست هیچ اثری نداشت. در هر 6 سطح، تا ضریب فشردگی 0.05، میانۀ $F1@0.5$ در هر گروه دقیقاً برابر مقدار پایه خودش است؛ بیشترین گستره درون هر گروه در کل محور برابر 0.0000 است. این آزمایش خراب نیست. این همان ناوردایی آفینی است که در فصل آستانه‌گذاری اثبات کردیم. فشرده کردن کنتراست حول میانۀ تصویر یک تبدیل آفین است، خط لوله در float32 کار می‌کند، پس نه بریدگی و نه کوانتیزاسیون وارد ماجرا نمی‌شوند و تبدیل هیچ راهی برای تغییر قطعه‌بندی ندارد. گزارش کردن یک منحنی تخت و توضیح دادنش، پاسخ درست است. ضمناً به ما می‌گوید آزمایش آموزنده کدام است.

9.6 کنتراست ضربدر نویز: نسخه‌ای که اطلاعات دارد


کنتراست فقط وقتی اهمیت دارد که چیز دیگری همراه آن کوچک نشود. پس کنتراست را فشرده می‌کنیم و سپس مقدار ثابتی نویز اضافه می‌کنیم: سیگنال کوچک می‌شود و کف نویز سر جایش می‌ماند. با σ برابر 0.02، $F1@0.5$ از 0.705 در کنتراست کامل به 0.489 در ضریب 0.15 و 0.053 در ضریب 0.05 سقوط می‌کند، در حالی که کل ردیف بدون نویز روی 0.715 ثابت مانده است. نتیجه فیزیکی: کمیتی که قطعه‌بندی را تعیین می‌کند نسبت سیگنال به کف نویز است، نه خود کنتراست. و این یافته عملی پروژه است، چون در یک میکروسکوپ واقعی افت کنتراست و کف نویز ثابت آشکارساز با هم می‌آیند.

جدول 9: شبکه دوعاملی: فشردگی کنتراست (ستون‌ها) در برابر نویز جمع‌شونده ثابتی که پس از آن اعمال می‌شود (ردیف‌ها). ردیف اول همان محور تخت کنتراست است.

Added noise σ	1	0.7	0.5	0.3	0.15	0.05
0	0.715	0.715	0.715	0.715	0.715	0.715
0.02	0.705	0.706	0.718	0.704	0.489	0.053
0.05	0.694	0.683	0.600	0.358	0.069	0.018

9.7 آیا این‌ها فقط شانس یک قرعه‌کشی نیستند؟

محورهای تصادفی در دو سطح، سه بار تکرار شدند. پراکندگی میان سه قرعه نویز از یک تصویر، تنها 0.063 تا 0.142 برابر پراکندگی میان تصاویر است. پس منحنی‌ها تفاوت میان تصاویر را اندازه می‌گیرند، نه نوسان یک نمونه‌گیری تصادفی.



شکل 3: میانۀ $F1@0.5$ در برابر سطح خرابی، یک خط برای هر گروه، با نوار اطمینان 95 درصدی بوتاسترپ درصدی روی میانه.

10 نتایج نهایی، و مقایسه با مراجع منتشرشده

جدول 10: watershed روی بخش آزمون کنارگذاشته‌شده، به تفکیک گروه مدالیت. پارامترها فقط روی بخش توسعه تنظیم شده‌اند.

Group	Images	Dice	F1@0.5	F1@0.7	DSB	Splits	Merges
Grayscale fluorescence	375	0.891	0.828	0.718	0.529	163	1,198
Colour histology	77	0.841	0.643	0.470	0.278	121	456
Grayscale brightfield	18	0.610	0.452	0.359	0.185	6	160
Macro average	470	0.781	0.641	0.515	0.331	290	1,814
All images (pooled)	470	0.872	0.784	0.663	0.475	290	1,814

عدد سرخط پروژه همین جدول است. روی کل بخش آزمون، Dice تجمیعی برابر 0.872 است – عددی که در نگاه اول یعنی «مسئله حل شده» – در حالی که $F1@0.5$ در سطح شیء 0.784 است، با 1,814 ادغام در برابر تنها 290 شکست، و 18,704 هسته پیش‌بینی‌شده در برابر 20,729 هسته واقعی.

به بیان دیگر: قطعه‌بند ماده هسته‌ای را درست پیدا می‌کند و بعد در تقسیم آن به تعداد درست اشیا شکست می‌خورد، عمدتاً با به هم چسباندن همسایه‌ها. و Dice تقریباً نابیناست نسبت به این اتفاق – که همان چیزی است که خودآزمایی روی تصویر مصنوعی نشان داد. میانگین ماکرو پایین‌تر است: Dice برابر 0.781 و $F1@0.5$ برابر 0.641، چون اجازه نمی‌دهد بزرگترین گروه به جای بقیه حرف بزند. گروه میدان روشن خاکستری ضعیف‌ترین است (Dice 0.610، $F1@0.5$ 0.452)، و دلیلش ساختاری است نه آماری: هسته‌های میدان روشن کنتراست کمی با سیتوپلاسم دارند و مرزهایشان نرم و تدریجی است، پس آستانه سراسری سطح تمیزی برای یافتن ندارد و تبدیل فاصله در درون یک لکه بدمرز، قله قابل‌اتکایی به watershed نمی‌دهد.

10.1 مقایسه با CellProfiler و U-Net: و اینکه چرا این یک برد نیست

فایل dataset/metadata.xlsx در جدول Suppl. Table S3 یک جدول امتیاز منتشرشده دارد، و چون معیارهای ما با همان تعاریف محاسبه شده‌اند، اعداد را می‌شود کنار هم گذاشت. اما این دو مجموعه هم‌ارز نیستند، و جدول باید همین را روی صورت خودش بنویسد.

جدول 11: مراجع منتشرشده DSB در آستانه IoU برابر 0.5، در کنار این پروژه. ستون «Scored on» بخشی از نتیجه است، نه یک زیرنویس.

Method	Scored on	$F1@0.5$	Official DSB score
[ods.ai] topcoders	DSB test sets	0.890	0.820
Jacobkie	DSB test sets	0.870	0.811
Deep Retina	DSB test sets	0.860	0.787
CellProfiler - Expert	DSB test sets	0.819	0.724
U-Net models	DSB test sets	0.734	0.638
CellProfiler - Novice	DSB test sets	0.705	0.589
This work – watershed, pooled over test images	stage1_train held-out	0.784	0.475
This work – watershed, macro over groups	stage1_train held-out	0.641	0.331

اگر ساده‌انگارانه بخوانیم، $F1@0.5$ (تجمیعی ما) 0.784 (بالتر از مدخل منتشرشده U-Net) 0.734 می‌نشیند. این مقایسه نامعتبر است و ما چنین ادعایی نمی‌کنیم.

دلیلش: مدخل‌های منتشرشده روی مجموعه‌های آزمون مسابقه (stage1_test و stage2_test) امتیاز گرفته‌اند، و آن مجموعه‌ها عمداً طوری ساخته شده بودند که انواع تصویربرداری و دشواری‌هایی داشته باشند که در stage1_train وجود ندارند. تقسیم ما اما یک افراز مبتنی بر درهم‌سازی از خود stage1_train است، که هم آسان‌تر است و هم 546 از 670 تصویرش هسته کوچک فلورسانس است – آسان‌ترین دسته این مجموعه. مقایسه صادقانه، امتیاز رسمی DSB است که در هر آستانه IoU از 0.5 تا 0.95 جریمه می‌کند و نسبت به مرزهای «تقریباً درست» بسیار سخت‌گیرتر است. روی آن معیار ما به 0.475 تجمیعی و 0.331 ماکرو می‌رسیم، در برابر 0.638 برای U-Net، 0.589 و 0.724 برای CellProfiler در دست کاربر تازمکار و کاربر خبره، و 0.820 برای تیم برنده.

یعنی روی معیاری که خود مسابقه از آن استفاده کرد، ما از همه مدخل‌های منتشرشده پایین‌تریم، با فاصله زیاد. و این دقیقاً جایگاه مورد انتظار و درست یک مرجع کلاسیک شفاف است. اگر عدد ما بالاتر از U-Net در می‌آمد، باید دنبال یک اشکال می‌گشتیم – تقریباً به‌طور قطع در تعریف معیار یا در نشت مجموعه آزمون.

11 مرور ماژول‌های src/

11.1 config.py

هر عدد قابل تنظیم پروژه در یک فایل. ثابت‌های ساده در سطح ماژول، بدون شیء پیکربندی. اگر نتیجه‌ای عوض شد، علتش یا داده است یا مقداری که اینجا نوشته شده – جای دیگری برای پنهان شدن یک عدد وجود ندارد. هر ثابت، استدلال مقدارش را همراه دارد، چون «چرا 0.03؟» همان پرسشی است که خواننده واقعاً خواهد داشت.

11.2 io_utils.py

بارگذاری RGBA به خاکستری (کانال آلفا پس از بررسی ثابت بودنش حذف می‌شود، نه پس از فرض کردنش)، ساخت تصویر برچسب حقیقت مرجع از ماسک‌های تکه‌سته‌ای و ذخیره‌سازی آن، تشخیص قطبیت، قاعده گروه‌بندی، و ساخت manifest.csv.

ذخیره‌سازی حقیقت مرجع بی‌دلیل نیست: ترکیب حدود بیستونه هزار فایل PNG کوچک، در هر اجرا دو تا چهار دقیقه ورودی/خروجی خالص می‌برد؛ با cache حدود ده ثانیه است.

11.3 preprocessing.py

چهار عمل فصل سوم، به‌علاوه preprocess_pipeline که آن‌ها را به ترتیب اعمال می‌کند و preprocess_steps که همان مسیر را گام‌به‌گام برمی‌گرداند تا بتوان نمودارش را کشید.

11.4 segmentation.py

سه قطعه‌بند، postprocess_mask، و دستور کامل watershed با رعایت همه دام‌های scikit-image که در فصل پنجم فهرست شد. تابع needs_three_class تصمیم می‌گیرد که برای سیتولوژی میدان روشن، به‌جای آستانه دوکلاسه از آستانه سه‌کلاسه Otsu استفاده شود – چون آنجا سیتوپلاسم یک کلاس شدت میانی می‌سازد که نه پس‌زمینه است و نه هسته.

11.5 metrics.py

ماتریس IoU برداری‌شده، تطبیق حریصانه، شمارنده‌های شکست و ادغام، F1@0.5 و F1@0.7، امتیاز رسمی DSB، و تابع summarize که همه این‌ها را به تفکیک گروه به‌علاوه ماکرو و تجمیعی جمع می‌بندد.

11.6 features.py

regionprops_table با نام‌های ویژگی نسخه‌های جدید scikit-image، به‌علاوه دو ستون مشتق مستقل از مقیاس، و خلاصه‌های آماری.

11.7 analysis.py

آماده‌سازی ماتریس (تبدیل log1p روی ستون‌های اندازه‌مانند، حذف ستون‌های تقریباً ثابت، استانداردسازی)، PCA، انتخاب k با سیلوئت، KMeans، و جدول‌های توصیف خوشه.

11.8 robustness.py

مدل‌های خرابی، نمونه‌گیری طبقه‌بندی‌شده، جاروب با دانه تصادفی مشتق‌شده برای هر خانه، جدا کردن دو بازو، بوت‌استرپ درصدی برای نوار اطمینان میانه، و اعتبارسنجی تحلیلی نويز.

visualization.py 11.9

همه شکل‌ها. هیچ‌کدام ترتیبی نیستند: شبکه گروه‌های مدالیت‌ها ابزار اعتبارسنجی قاعده گروه‌بندی است، و هم‌پوشانی قطعه‌بندی جایی است که یک خطای قطبیت یا یک watershed بیش از حد شکننده دیده می‌شود، به‌جای اینکه به‌صورت یک عدد کمی ناامیدکننده در جدول ظاهر شود.

reports.py و latex_tables.py 11.10

تبدیل فایل‌های CSV نتایج به قطعه‌های LaTeX، و ساخت هر دو گزارش. هیچ عددی در هیچ‌یک از دو گزارش تایپ نشده است: یا از یک جدول تولیدشده می‌آید یا از یک ماکرو در numbers.tex. اگر پارامتری عوض شود و خط لوله دوباره اجرا شود، متن گزارش هم با آن عوض می‌شود - و اگر نتیجه‌ای حذف شود، گزارش به‌جای چاپ عدد کهنه، اصلاً ساخته نمی‌شود.

12 اجرای پروژه

```
python3.11 -m venv .venv
.venv/bin/pip install -r requirements.txt
.venv/bin/python run_all.py
```

```
python run_all.py --limit 40      # a quick trial run
python run_all.py --tables-only   # rebuild the tables and both PDFs only
```

یک اجرای کامل روی همه 670 تصویر حدود هفده دقیقه طول می‌کشد و تقریباً تمام آن در جاروب پایداری اندازه‌گیری صرف می‌شود، که برای هر تصویر نمونه‌گیری شده حدود پنجاه بار کل خط لوله را دوباره اجرا می‌کند. مسیر تأییدشده همان venv بالاست. فایل environment.yml برای قابلیت حمل عرضه شده اما هرگز حل نشده است، چون روی ماشین‌هایی که این پروژه ساخته شد conda نصب نبود.

13 محدودیت‌ها و کارهای آینده

- تقسیم آزمون یک افراز از stage1_train است نه مجموعه‌های آزمون خود مسابقه، پس اعداد مطلق نسبت به هر نتیجه منتشرشده DSB خوش‌بینانه‌اند.
- گروه میدان روشن خاکستری در کل مجموعه فقط 21 تصویر دارد. ترتیب (ضعیف‌ترین بودنش) قابل اتکاست؛ مقدار دقیقش نه.
- پارامترها با جاروب‌های تک‌بعدی تنظیم شده‌اند نه به‌صورت مشترک، و watershed از یک h واحد برای مجموعه‌ای استفاده می‌کند که شعاع هسته‌هایش شش برابر تغییر می‌کند. امیدبخش‌ترین گسترش، یک h تطبیقی برای هر تصویر است که با شعاع میانه برآوردشده همان تصویر مقیاس بگیرد.
- ویژگی‌های شدت نه میان نوردهی‌های مختلف قابل مقایسه‌اند و نه میان سطوح نویز.
- مدل‌های خرابی مصنوعی و مستقل‌اند؛ یک میکروسکوپ واقعی تاری، نویز شات و افت کنتراست را با هم و هم‌بسته تحویل می‌دهد.

- Caicedo, J.C., Goodman, A., Karhohs, K.W., Cimini, B.A., Ackerman, J., Haghighi, M., Heng, C., Becker, T., Doan, M., McQuin, C., Rohban, M., Singh, S., and Carpenter, A.E. (2019). Nucleus segmentation across imaging experiments: the 2018 Data Science Bowl. *Nature Methods* 16(12), 1247–1253. doi:10.1038/s41592-019-0612-7
- Ljosa, V., Sokolnicki, K.L., and Carpenter, A.E. (2012). Annotated high-throughput microscopy image sets for validation. *Nature Methods* 9(7), 637. doi:10.1038/nmeth.2083 — the Broad Bioimage Benchmark Collection, which distributes this data as BBBC038v1: bbbc.broadinstitute.org/BBBC038